



Análise de Agrupamentos

O que é clustering?


É uma **técnica estatística multivariada** para identificar agrupamentos dos dados de acordo com o grau de semelhança. Queremos achar um grupo de objetos, que são similares entre si e diferentes de outros grupos.



- O **objetivo** típico em clustering é descobrir os “agrupamentos naturais” presente nos dados.



O que é clustering?

- ▶ Conjunto de dados **contendo** agrupamentos “naturais”:



O que é clustering?

- Conjunto de dados **sem** agrupamentos “naturais”:



Tendência de agrupamentos: “Faz sentido aplicar um algoritmo de clusterização nesses dados?”

Método estatístico: Estatística de Hopkins

A **Estatística de Hopkins** é uma medida pré-clusterização muito usada para avaliar se um conjunto de dados apresenta tendência natural à formação de agrupamentos (clusters) ou se os pontos estão distribuídos de forma aproximadamente aleatória no espaço das variáveis.

Tendência de agrupamentos: “Faz sentido aplicar um algoritmo de clusterização nesses dados?”

Método estatístico: Estatística de Hopkins

- ▶ A ideia central é comparar distâncias:
 - ▶ Distâncias entre pontos reais do conjunto de dados
 - ▶ Distâncias entre pontos artificiais gerados aleatoriamente no mesmo espaço amostral
- ▶ Se os dados tiverem estrutura de clusters, os pontos reais tendem a estar mais próximos entre si do que pontos gerados aleatoriamente.

Tendência de agrupamentos: “Faz sentido aplicar um algoritmo de clusterização nesses dados?”

Método estatístico: Estatística de Hopkins

- Considerando um inteiro $m \ll n$, de pontos amostrados (normalizados), calcula-se a distância de cada ponto até o vizinho mais próximo, excluindo o próprio ponto

$$w_i = \min_{x_j \in X \setminus \{x_i\}} d(x_i, x_j), \quad i = 1, \dots, m$$

Tendência de agrupamentos: “Faz sentido aplicar um algoritmo de clusterização nesses dados?”

Método estatístico: Estatística de Hopkins

- Geram-se m pontos artificiais $y_1, \dots, y_m$, assumindo distribuição uniforme no hipercubo definido pelos limites dos dados e independência entre as dimensões. Para cada ponto artificial j , calcula-se a distância até o vizinho mais próximo no conjunto real.

$$u_i = \min_{x \in X} d(y_i, x), \quad i = 1, \dots, m$$

Tendência de agrupamentos: “Faz sentido aplicar um algoritmo de clusterização nesses dados?”

Método estatístico: Estatística de Hopkins

$$H = \frac{\sum_{i=1}^m u_i}{\sum_{i=1}^m u_i + \sum_{i=1}^m w_i}$$

- ▶ w_i : distância do ponto real ao vizinho mais próximo
- ▶ u_i : distância do ponto artificial ao ponto real mais próximo

Tendência de agrupamentos: “Faz sentido aplicar um algoritmo de clusterização nesses dados?”

Interpretação da Estatística de Hopkins

Sob a hipótese de ausência de clusters (padrão de referência), espera-se que as distâncias u_i e w_i sejam, em média, comparáveis, o que leva a:

$$H \approx 0.5$$

Em termos práticos:

- ▶ $H \approx 0.5$: dados compatíveis com **padrão aleatório** (baixa tendência à clusterização);
- ▶ $H > 0.5$: evidência de **tendência à formação de clusters** (quanto mais próximo de 1, mais agregado);
- ▶ $H < 0.5$: padrão mais **regular ou espalhado** do que o aleatório.

Tendência de agrupamentos: “Faz sentido aplicar um algoritmo de clusterização nesses dados?”

Interpretação da Estatística de Hopkins

Observação: como H depende de amostragem aleatória (seleção dos m pontos e geração dos pontos artificiais), é recomendável repetir o cálculo várias vezes e resumir o resultado por média ou mediana.

Tendência de agrupamentos

Método visual: Avaliação visual da tendência de agrupamento (VAT)

- ▶ A Avaliação Visual da Tendência de Agrupamento (VAT) é um método exploratório que avalia, de forma gráfica, se um conjunto de dados apresenta evidência de agrupamentos naturais.
- ▶ O procedimento baseia-se na matriz de distâncias entre as observações. Após o cálculo da matriz


$$D = [d(x_i, x_j)]_{n \times n},$$

as observações são reordenadas de modo que pontos similares fiquem próximos, e a matriz resultante é exibida como um mapa de calor.

Tendência de agrupamentos

Método visual: Avaliação visual da tendência de agrupamento (VAT)

Wine data



Tendência de agrupamentos

Método visual: Avaliação visual da tendência de agrupamento (VAT)

- ▶ A interpretação é feita visualmente:
 - ▶ blocos escuros ao longo da diagonal indicam possível presença de clusters;
 - ▶ ausência de blocos bem definidos sugere padrão aleatório ou ausência de estrutura de agrupamento.
- ▶ O VAT é uma ferramenta pré-clusterização e deve ser utilizado de forma complementar a medidas quantitativas, como a Estatística de Hopkins.

Que perguntas a clusterização pode responder?

A clusterização é uma técnica de aprendizado não supervisionado cujo objetivo é identificar grupos de observações semelhantes, sem rótulos prévios. Ela é usada tanto como **objetivo final** quanto como **ferramenta de apoio à decisão**.

Que perguntas a clusterização pode responder?

A clusterização é uma técnica de aprendizado não supervisionado cujo objetivo é identificar grupos de observações semelhantes, sem rótulos prévios. Ela é usada tanto como **objetivo final** quanto como **ferramenta de apoio à decisão**.

► Como agrupo os clientes que compram no site?

A clusterização permite identificar perfis de clientes com comportamentos de compra semelhantes, apoiando estratégias de segmentação e marketing.

Que perguntas a clusterização pode responder?

A clusterização é uma técnica de aprendizado não supervisionado cujo objetivo é identificar grupos de observações semelhantes, sem rótulos prévios. Ela é usada tanto como **objetivo final** quanto como **ferramenta de apoio à decisão**.

► Como agrupo os clientes que compram no site?

A clusterização permite identificar perfis de clientes com comportamentos de compra semelhantes, apoiando estratégias de segmentação e marketing.

► Onde coloco uma antena de operadora de celular?

A partir da clusterização espacial de usuários ou regiões, é possível identificar áreas de alta concentração de demanda, sugerindo locais estratégicos para instalação.

Que perguntas a clusterização pode responder?

- ▶ **Onde deixo uma ambulância estacionada para atender uma emergência?**

A clusterização de ocorrências passadas ajuda a identificar zonas críticas, auxiliando na alocação eficiente de recursos de emergência.

Que perguntas a clusterização pode responder?

- ▶ **Onde deixo uma ambulância estacionada para atender uma emergência?**

A clusterização de ocorrências passadas ajuda a identificar zonas críticas, auxiliando na alocação eficiente de recursos de emergência.

- ▶ **Como classifico cervejas em categorias distintas?**

A clusterização explora similaridades entre produtos e pode revelar categorias naturais ou estilos semelhantes, apoiando a construção de classificações.

Algumas questões...

Como medir a homogeneidade entre indivíduos?

E entre grupos de indivíduos?

Dado um conjunto de indivíduos, quantos grupos posso formar?

Algumas questões...

Imagine que você tenha 16 cartas figuradas (A, K, Q, J) e que queira formar grupos de cartas semelhantes...



Como você formaria
esses grupos?

Algumas questões...


	♠	♣	♦	♥
A				
K				
Q				
J				

(a) Cartas individuais?


	♠	♣	♦	♥
A				
K				
Q				
J				

(a) Agrupar por naipes?

Algumas questões...




(a) Agrupar por cor do naipe?



(a) Agrupar por naipes maiores e menores?

Algumas questões...



(a) Copas mais a Rainha de espadas e outros naipes?



(a) Agrupar por face da carta?

Algumas questões...

Resumindo...

Necessidade da definição de medidas de **similaridade** (ou dissimilaridade)



Similaridade e dissimilaridade

Medidas de Similaridade: quanto **maior** o valor, **maior a semelhança** entre os objetos

Similaridade e dissimilaridade

Medidas de Similaridade: quanto **maior** o valor, **maior a semelhança** entre os objetos

Medidas de Dissimilaridade (Distância): quanto **maior** o valor, **mais diferentes** são os objetos

Similaridade e dissimilaridade (exemplo)

Pesquisa com clientes de uma loja de equipamentos automotivos

Similaridade e dissimilaridade (exemplo)

Pesquisa com clientes de uma loja de equipamentos automotivos

Variáveis mensuradas

- ▶ **Idade** (em anos completos) - Variável quantitativa discreta
- ▶ **Número de carros** - Variável quantitativa discreta
- ▶ **Classe social**: A, B, C ou D - Variável qualitativa ordinal
- ▶ **Potência do motor**: Baixa, Média ou Alta - Variável qualitativa ordinal
- ▶ **Combustível**: Gasolina ou Álcool - Variável qualitativa nominal
- ▶ **Modelo**: Esporte, Luxo ou Standard - Variável qualitativa nominal

Base de dados (exemplo)

Cliente	Idade	N.º de carros	Classe social	Potência do motor	Combustível	Modelo
1	20	1	A	Baixa	Gasolina	Esporte
2	37	2	A	Alta	Gasolina	Luxo
3	51	1	C	Média	Gasolina	Esporte
4	32	1	D	Alta	Álcool	Standard
5	30	2	B	Média	Álcool	Standard
6	55	3	A	Alta	Gasolina	Luxo

Base de dados (exemplo)

Cliente	Idade	N.º de carros	Classe social	Potência do motor	Combustível	Modelo
1	20	1	A	Baixa	Gasolina	Esporte
2	37	2	A	Alta	Gasolina	Luxo
3	51	1	C	Média	Gasolina	Esporte
4	32	1	D	Alta	Álcool	Standard
5	30	2	B	Média	Álcool	Standard
6	55	3	A	Alta	Gasolina	Luxo

Como medir a similaridade ou dissimilaridade entre os indivíduos?

Variáveis quantitativas

Dissimilaridade



As **distâncias** são as medidas de **dissimilaridade** mais utilizadas no estudo de bancos de dados com variáveis numéricas

Dissimilaridade

As **distâncias** são as medidas de **dissimilaridade** mais utilizadas no estudo de bancos de dados com variáveis numéricas

- Uma medida d_{ij} representa uma **medida de distância** entre os indivíduos i e j se, e somente se,
- a) $d_{ij} \geq 0$ para todo i e j ;
 - b) $d_{ij} = 0$ se, e somente se, $i = j$;
 - c) $d_{ij} = d_{ji}$
 - d) $d_{ij} \leq d_{ik} + d_{kj}$ para qualquer indivíduo k .

Dissimilaridade



Dissimilaridade

Principais medidas de distância

Distância Euclidiana

$$d_{ij} = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^t (\mathbf{x}_i - \mathbf{x}_j)} = \sqrt{\sum_{k=1}^p (x_{ik} - x_{jk})^2}$$

Distância geométrica entre dois pontos

Dissimilaridade

Principais medidas de distância

Distância Euclidiana Generalizada

$$d_{ij} = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^t W (\mathbf{x}_i - \mathbf{x}_j)}$$

- ▶ Se $W = \text{diag}\left(\frac{1}{p}\right)$: **distância euclidiana média**
- ▶ Se $W = \Sigma^{-1}$: **distância de Mahalanobis**

Dissimilaridade

Principais medidas de distância

Distância de Minkowski


$$d_{ij} = \left(\sum_{k=1}^P |X_{ik} - X_{jk}|^\lambda \right)^{\frac{1}{\lambda}}$$

- ▶ Se $\lambda = 1$, temos a chamada **métrica de Manhattan**. É também conhecida como *city block*.
- ▶ Se $\lambda = 2$, temos a distância euclidiana.
- ▶ A métrica de Minkowski é menos afetada pela presença de valores discrepantes na amostra do que a distância Euclidiana.

Dissimilaridade

Principais medidas de distância

Distância de Manhattan (city block)



Dissimilaridade

Dissimilaridade $\implies$ Similaridade

$$s_{ij} = 1 - d_{ij}^0$$

em que

$$d_{ij}^0 = \frac{d_{ij} - \min(D)}{\max(D) - \min(D)}$$

Sendo $\min(D)$ e $\max(D)$ o menor e o maior valor de distância observados na matriz de distâncias $D_{n \times n}$, sem levar em consideração os elementos da diagonal principal dessa matriz.

Variáveis qualitativas

Similaridade

Variáveis qualitativas nominais

Neste caso, utilizamos variáveis fictícias (variáveis *dummy*) para **codificar** as variáveis:

Combustível	N_1
Gasolina	1
Álcool	0

Modelo	N_2	N_3
Esporte	1	0
Luxo	0	1
Standard	0	0

Similaridade

Variáveis qualitativas nominais

No exemplo:

Cliente	Combustível	N_1
1	Gasolina	1
2	Gasolina	1
3	Gasolina	1
4	Álcool	0
5	Álcool	0
6	Gasolina	1

Cliente	Modelo	N_2	N_3
1	Esporte	1	0
2	Luxo	0	1
3	Esporte	1	0
4	Standard	0	0
5	Standard	0	0
6	Luxo	0	1

Similaridade

Variáveis qualitativas nominais

De forma que,

Cliente	N_1	N_2	N_3
1	1	1	0
2	1	0	1
3	1	1	0
4	0	0	0
5	0	0	0
6	1	0	1

Similaridade

Variáveis qualitativas ordinais

Utilizamos variáveis fictícias (variáveis *dummy*) para **codificar** as variáveis, levando em consideração a ordinalidade das variáveis:

Classe social	O_1	O_2	O_3
A	1	1	1
B	0	1	1
C	0	0	1
D	0	0	0

Potência	O_4	O_5
Alta	1	1
Média	0	1
Baixa	0	0

Similaridade

Observação

As variáveis **Classe social** e **Potência do motor** possuem **ordem natural**. Por isso, foram codificadas por meio de **variáveis ordinais cumulativas**:

- ▶ valores mais altos acumulam mais indicadores iguais a 1;
- ▶ valores mais baixos recebem apenas zeros.

Essa codificação preserva a informação de ordem, mas impõe uma estrutura geométrica específica ao espaço dos dados.

Similaridade

Variáveis qualitativas ordinais

No exemplo:

Cliente	Classe social	O_1	O_2	O_3
1	A	1	1	1
2	A	1	1	1
3	C	0	0	1
4	D	0	0	0
5	B	0	1	1
6	A	1	1	1

Cliente	Potência	O_4	O_5
1	Baixa	0	0
2	Alta	1	1
3	Média	0	1
4	Alta	1	1
5	Média	0	1
6	Alta	1	1

Similaridade

Variáveis qualitativas ordinais

De forma que,

Cliente	O_1	O_2	O_3	O_4	O_5
1	1	1	1	0	0
2	1	1	1	1	1
3	0	0	1	0	1
4	0	0	0	1	1
5	0	1	1	0	1
6	1	1	1	1	1

Similaridade

Variáveis qualitativas nominais e ordinais

Juntando tudo...

Cliente	O_1	O_2	O_3	O_4	O_5	N_1	N_2	N_3
1	1	1	1	0	0	1	1	0
2	1	1	1	1	1	1	0	1
3	0	0	1	0	1	1	1	0
4	0	0	0	1	1	0	0	0
5	0	1	1	0	1	0	0	0
6	1	1	1	1	1	1	0	1

Similaridade

Variáveis qualitativas nominais e ordinais

Considere os clientes 1 e 3. Vamos calcular a medida de similaridade entre eles:

Cliente	O_1	O_2	O_3	O_4	O_5	N_1	N_2	N_3
1	1	1	1	0	0	1	1	0
3	0	0	1	0	1	1	1	0

Similaridade

Tabela de concordância entre dois indivíduos

Indivíduo $i \setminus$ Indivíduo j	1	0	Total
1	a	b	$a + b$
0	c	d	$c + d$
Total	$a + c$	$b + d$	p

- ▶ a : número de variáveis em que ambos têm valor 1
- ▶ b : número de variáveis em que $i = 1$ e $j = 0$
- ▶ c : número de variáveis em que $i = 0$ e $j = 1$
- ▶ d : número de variáveis em que ambos têm valor 0

$$p = a + b + c + d$$

Similaridade

Tabela de concordância entre dois indivíduos

No exemplo:

Indivíduo 1 \ Indivíduo 3	1	0	Total
1	3	2	5
0	1	2	3
Total	4	4	8

Como extrair as **medidas de similaridade** baseadas na **tabela de concordância** dos elementos?

Cr terios de similaridade

Coeficiente de Concord ncia Simples

$$s_{ij} = \frac{a + d}{p}$$

Indiv�duo 1 \ Indiv�duo 3	1	0	Total
1	3	2	5
0	1	2	3
Total	4	4	8

$$s_{13} = \frac{a + d}{p} = \frac{3 + 2}{8} = \frac{5}{8} = 0,625$$

Critérios de similaridade

Coeficiente de Concordância Simples

Interpretação:

- ▶ O valor 0,625 indica que os indivíduos 1 e 3 concordam em 62,5% das variáveis binárias.
- ▶ Tanto concordâncias em 1 quanto em 0 contribuem igualmente para a similaridade.

Cr terios de similaridade

Coeficiente de Concord ncia Positiva

$$s_{ij} = \frac{a}{p}$$

Ind�v�duo 1 \ Ind�v�duo 3	1	0	Total
1	3	2	5
0	1	2	3
Total	4	4	8

$$s_{13} = \frac{a}{p} = \frac{3}{8} = 0,375$$

Critérios de similaridade

Coeficiente de Concordância Positiva

Interpretação:

- ▶ Os indivíduos 1 e 3 compartilham simultaneamente o valor 1 em **37,5%** das variáveis.
- ▶ Ausências simultâneas (valor 0) **não contribuem** para a similaridade.
- ▶ O critério enfatiza **presença conjunta**, não coincidência geral.

Cr terios de similaridade

Coeficiente de Concord ncia de Jaccard

$$s_{ij} = \frac{a}{a + b + c}$$

$$s_{13} = \frac{3}{3 + 2 + 1} = \frac{3}{6} = 0,5$$

Indiv�duo 1 \ Indiv�duo 3	1	0	Total
1	3	2	5
0	1	2	3
Total	4	4	8

Cr terios de similaridade

Coeficiente de Concord ncia de Jaccard

Interpreta  o:

- ▶ Os indiv duos 1 e 3 compartilham **50% das presen as observadas**.
- ▶ Aus ncias simult neas (valor 0) **n o contribuem** para a similaridade.
- ▶ O coeficiente foca exclusivamente na **interse  o de atributos presentes**.

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

O **Coeficiente de Concordância de Gower–Legendre** é uma medida de similaridade projetada para **dados mistos**, isto é, conjuntos de dados que contêm, ao mesmo tempo:

- ▶ variáveis quantitativas,
- ▶ variáveis qualitativas nominais,
- ▶ variáveis qualitativas ordinais.

Ele permite combinar diferentes tipos de variáveis em **uma única medida de similaridade**, respeitando a natureza de cada uma.

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

Considere dois indivíduos i e j descritos por p variáveis. A similaridade de Gower–Legendre é definida como:

$$S_{ij} = \frac{\sum_{k=1}^p w_{ijk} s_{ijk}}{\sum_{k=1}^p w_{ijk}},$$

onde:

- ▶ s_{ijk} é a similaridade parcial da variável k entre os indivíduos i e j ;
- ▶ w_{ijk} é um peso (geralmente 0 ou 1), usado para tratar dados ausentes.

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

O coeficiente assume valores em $[0, 1]$:

- ▶ $S_{ij} = 1$ indica indivíduos idênticos;
- ▶ $S_{ij} = 0$ indica máxima dissimilaridade.

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

Similaridade parcial por tipo de variável

Variáveis quantitativas

► Para uma variável quantitativa k :

$$s_{ijk} = 1 - \frac{|x_{ik} - x_{jk}|}{R_k},$$

onde R_k é o intervalo da variável k (máximo — mínimo).

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

Similaridade parcial por tipo de variável

Variáveis qualitativas nominais

► Para uma variável nominal:

$$s_{ijk} = \begin{cases} 1, & \text{se } x_{ik} = x_{jk}, \\ 0, & \text{caso contrário.} \end{cases}$$

Cr terios de similaridade

Coeficiente de Concord ncia de Gower e Legendre

Similaridade parcial por tipo de vari vel

Vari veis qualitativas ordinais

Para vari veis ordinais, os n veis s o primeiro convertidos em **postos normalizados** no intervalo $[0, 1]$. Em seguida, aplica-se a mesma f rmula das vari veis quantitativas:

$$s_{ijk} = 1 - |r_{ik} - r_{jk}|,$$

onde r_{ik} e r_{jk} s o os postos normalizados.

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

Interpretação:

- ▶ Cada variável contribui **de forma controlada** para a similaridade total.
- ▶ Variáveis com escalas diferentes **não dominam** o cálculo.
- ▶ A ordem das categorias é respeitada para variáveis ordinais, **sem impor distâncias artificiais**.

Critérios de similaridade

Similaridade $\Rightarrow$ Dissimilaridade

$$d_{ij}^* = 1 - s_{ij}$$

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

No exemplo:

Cliente	Idade	N.º de carros	Classe social	Potência do motor	Combustível	Modelo
1	20	1	A	Baixa	Gasolina	Esporte
2	37	2	A	Alta	Gasolina	Luxo
3	51	1	C	Média	Gasolina	Esporte
4	32	1	D	Alta	Álcool	Standard
5	30	2	B	Média	Álcool	Standard
6	55	3	A	Alta	Gasolina	Luxo

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

Temos que:

- ▶ **Cliente 1:** Idade = 20, Carros = 1, Classe = A, Potência = Baixa, Combustível = Gasolina, Modelo = Esporte
- ▶ **Cliente 3:** Idade = 51, Carros = 1, Classe = C, Potência = Média, Combustível = Gasolina, Modelo = Esporte

Cr terios de similaridade

Coeficiente de Concord ncia de Gower e Legendre

Similaridades parciais

► **Idade**

$$s = 1 - \frac{|20 - 51|}{35} = 1 - \frac{31}{35} = \frac{4}{35} \approx 0,1143$$

► **N  de carros**

$$s = 1 - \frac{|1 - 1|}{2} = 1$$

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

Similaridades parciais

► **Classe social (ordinal)**

$r(A) = 1$ e $r(C) = \frac{1}{3}$:

$$s = 1 - \left| 1 - \frac{1}{3} \right| = 1 - \frac{2}{3} = \frac{1}{3} \approx 0,3333$$

► **Potência (ordinal)**

$r(\text{Baixa}) = 0$ e $r(\text{Média}) = \frac{1}{2}$:

$$s = 1 - \left| 0 - \frac{1}{2} \right| = \frac{1}{2} = 0,5$$

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

Similaridades parciais

► **Combustível (nominal)**

Gasolina = Gasolina $\Rightarrow s = 1$

► **Modelo (nominal)**

Esporte = Esporte $\Rightarrow s = 1$

Critérios de similaridade

Coeficiente de Concordância de Gower e Legendre

Similaridade total

São $p = 6$ variáveis:

$$S_{1,3} = \frac{0,1143 + 1 + 0,3333 + 0,5 + 1 + 1}{6} \approx 0,6579$$

Métodos de Agrupamento

Métodos de Agrupamento


- ▶ **Métodos hierárquicos:** Baseiam-se na realização de sucessivas aglomerações ou de sucessivas divisões dos dados. Envolvem a construção de uma hierarquia através de uma estrutura do tipo árvore.

Métodos de Agrupamento

- ▶ **Métodos hierárquicos:** Baseiam-se na realização de sucessivas aglomerações ou de sucessivas divisões dos dados. Envolvem a construção de uma hierarquia através de uma estrutura do tipo árvore.
- ▶ **Métodos não-hierárquicos:** Produzem uma partição em um número fixo de classes, com sucessivas alocações e re-alocações dos indivíduos, conforme as distâncias aos demais indivíduos. Necessário definir o número de grupos à *{priori}*.


Métodos hierárquicos

- **Aglomerativos:** Os agrupamentos são formados a partir de uma matriz de parença, que é atualizada a cada união de um par de objetos. Neste procedimento, cada indivíduo, originalmente, é um cluster, configurando n clusters. Indivíduos similares são sucessivamente agrupados, até a formação de um único grupo, contendo toda a amostra.



Métodos hierárquicos

- **Divisivos (ou de Partição):** Fazem o caminho oposto aos métodos hierárquicos aglomerativos. Neste método, um único grupo de objetos é subdividido em dois com a maior distância. Estes subgrupos são então particionados sucessivamente até se obter os objetos individuais.




Métodos de Agrupamento Hierárquicos

Agrupamentos hierárquicos aglomerativos

- a) Considerar inicialmente n grupos, sendo n o número de indivíduos. A matriz de distâncias $D_{n \times n}$ é a matriz de distâncias entre os elementos originais;
- b) Selecionar os dois indivíduos mais próximos na matriz $D_{n \times n}$ e formar com eles um grupo;
- c) Substituir os indivíduos utilizados no passo b) para definir o grupo por um novo elemento que represente o grupo construído. A distância entre esse novo elemento e os indivíduos restantes são calculadas utilizando um dos critérios que serão definidos a seguir;
- d) Voltar ao passo b) e repetir os passos b) e c) até que tenhamos todos os elementos agrupados em um único grupo.

Métodos de Agrupamento Hierárquicos

Resultado da aplicação do método



- ▶ Representa uma síntese gráfica do método de agrupamento
- ▶ Esse gráfico é de grande utilidade para a classificação, comparação e discussão de agrupamentos.

Métodos de Agrupamento Hierárquicos

Como definir distância entre grupos?


- ▶ Suponha que temos um grupo K com n_k indivíduos e um grupo L com n_l indivíduos.
- ▶ A distância entre os grupos K e L pode ser calculada com base em um dos cinco métodos seguintes:
 - ▶ Método do vizinho mais próximo (*single linkage*)
 - ▶ Método do vizinho mais distante (*complete linkage*)
 - ▶ Método da distância média (*average linkage*)
 - ▶ Método do centroide (*Centroid*)
 - ▶ Método de Ward

Métodos de Agrupamento Hierárquicos

Método do vizinho mais próximo

Consiste em considerar que a distância entre os dois grupos é a **menor distância entre as possíveis combinações de indivíduos** tomados dos dois grupos considerados, isto é,



$$d_{(K,L)} = \underbrace{\min(d_{ij})}_{i \in K, j \in L}$$



Métodos de Agrupamento Hierárquicos

Método do vizinho mais próximo





Esquematicamente:



Métodos de Agrupamento Hierárquicos

Método do vizinho mais próximo

Esquematicamente:




Métodos de Agrupamento Hierárquicos

Método do vizinho mais distante

Consiste em considerar que a distância entre os dois grupos é a **maior distância entre as possíveis combinações de indivíduos** tomados dos dois grupos considerados, isto é,

$$d_{(K,L)} = \max_{i \in K, j \in L} (d_{ij})$$




Métodos de Agrupamento Hierárquicos

Método da distância média

Consiste em considerar que a distância entre os dois grupos é a **média aritmética das distâncias entre as possíveis combinações de indivíduos** tomados dos dois grupos considerados, isto é,

$$d_{(K,L)} = \sum_{i \in K} \sum_{j \in L} \frac{d_{ij}}{n_k n_l}$$




Métodos de Agrupamento Hierárquicos

Método do centroide

Consiste em considerar que a distância entre os dois grupos é a **distância euclidiana ao quadrado entre os centroides** dos dois grupos. O centroide de um grupo é o ponto médio dos objetos contidos no grupo, isto é,

$$d_{(K,L)} = (\bar{K} - \bar{L})^t (\bar{K} - \bar{L})$$

$$\bar{K} = \frac{\sum_{i \in K} i}{n_k} \text{ e } \bar{L} = \frac{\sum_{j \in L} j}{n_l}$$



Métodos de Agrupamento Hierárquicos

Método de Ward

- Considere a soma de quadrados intra-cluster de um cluster A :

$$SQE_A = \sum_{i=1}^{n_A} (x_i - \bar{\mathbf{x}}_A)^t (x_i - \bar{\mathbf{x}}_A)$$

- Definimos o acréscimo na soma de quadrados resultante da junção de dois clusters A e B em um cluster AB por:

$$I_{AB} = SQE_{AB} - (SQE_A + SQE_B)$$

Métodos de Agrupamento Hierárquicos

Método de Ward

- ▶ A união entre clusters A e B que proporcionarem menor acréscimo na SQE é executada.
- ▶ Para usar o método de Ward, as variáveis devem ser **quantitativas**.

Métodos de Agrupamento Hierárquicos

Exemplo


A fim de exemplificar a aplicação dos métodos de agrupamento, considere os dados da Tabela ao lado. Os sete casos são considerados as observações de cada indivíduo para as variáveis X_1 e X_2 .

Caso	X_1	X_2
1	1	1
2	2	1
3	3	2
4	2	4,5
5	1	5
6	3	7
7	6	5

Métodos de Agrupamento Hierárquicos

Exemplo

Representação dos casos no plano



Métodos de Agrupamento Hierárquicos

Exemplo

Matriz de distâncias

$$D_0 = \begin{matrix} & \begin{matrix} 1 & 2 & 3 & 4 & 5 & 6 & 7 \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \\ 7 \end{matrix} & \begin{bmatrix} 0,000 & 1,000 & 2,236 & 3,640 & 4,000 & 6,325 & 6,403 \\ & 0,000 & 1,414 & 3,500 & 4,123 & 6,083 & 5,657 \\ & & 0,000 & 2,693 & 3,606 & 5,000 & 4,243 \\ & & & 0,000 & 1,118 & 2,693 & 4,031 \\ & & & & 0,000 & 2,828 & 5,000 \\ & & & & & 0,000 & 3,606 \\ & & & & & & 0,000 \end{bmatrix} \end{matrix}$$

Métodos de Agrupamento Hierárquicos

Exemplo

Matriz de distâncias

$$D_0 = \begin{bmatrix} & 1 & 2 & 3 & 4 & 5 & 6 & 7 \\ 1 & 0,000 & \mathbf{1,000} & 2,236 & 3,640 & 4,000 & 6,325 & 6,403 \\ 2 & & 0,000 & 1,414 & 3,500 & 4,123 & 6,083 & 5,657 \\ 3 & & & 0,000 & 2,693 & 3,606 & 5,000 & 4,243 \\ 4 & & & & 0,000 & 1,118 & 2,693 & 4,031 \\ 5 & & & & & 0,000 & 2,828 & 5,000 \\ 6 & & & & & & 0,000 & 3,606 \\ 7 & & & & & & & 0,000 \end{bmatrix}$$

$$d_{12} = \sqrt{(X_{11} - X_{21})^2 + (X_{12} - X_{22})^2} = \sqrt{(1 - 1)^2 + (2 - 1)^2} = \sqrt{1} = 1$$

Métodos de Agrupamento Hierárquicos

Exemplo

Passo 1: juntar os casos 1 e 2

- ▶ Redefinir a matriz de distâncias considerando os casos mais parecidos como se fossem um único grupo.
- ▶ **Aqui os métodos se diferenciam!**
- ▶ **Método do vizinho mais próximo**

Métodos de Agrupamento Hierárquicos

Exemplo

Construção da nova matriz de distâncias

$$d_{((1,2)3)} = \min(d_{13}; d_{23}) = \min(2, 236; 1, 414) = 1, 414$$

$$d_{((1,2)4)} = \min(d_{14}; d_{24}) = \min(3, 640; 3, 500) = 3, 500$$

$$d_{((1,2)5)} = \min(d_{15}; d_{25}) = \min(4, 000; 4, 123) = 4, 000$$

$$d_{((1,2)6)} = \min(d_{16}; d_{26}) = \min(6, 325; 6, 083) = 6, 083$$

$$d_{((1,2)7)} = \min(d_{17}; d_{27}) = \min(6, 403; 5, 657) = 5, 657$$

Métodos de Agrupamento Hierárquicos

Exemplo

Matriz de distâncias

$$D_1 = \begin{bmatrix} & (1,2) & 3 & 4 & 5 & 6 & 7 \\ (1,2) & 0,000 & 1,414 & 3,500 & 4,000 & 6,083 & 5,657 \\ 3 & & 0,000 & 2,693 & 3,606 & 5,000 & 4,243 \\ 4 & & & 0,000 & 1,118 & 2,693 & 4,031 \\ 5 & & & & 0,000 & 2,828 & 5,000 \\ 6 & & & & & 0,000 & 3,606 \\ 7 & & & & & & 0,000 \end{bmatrix}$$

Métodos de Agrupamento Hierárquicos

Exemplo

Matriz de distâncias

$$D_1 = \begin{bmatrix} & (1,2) & 3 & 4 & 5 & 6 & 7 \\ (1,2) & 0,000 & 1,414 & 3,500 & 4,000 & 6,083 & 5,657 \\ 3 & & 0,000 & 2,693 & 3,606 & 5,000 & 4,243 \\ 4 & & & 0,000 & \mathbf{1,118} & 2,693 & 4,031 \\ 5 & & & & 0,000 & 2,828 & 5,000 \\ 6 & & & & & 0,000 & 3,606 \\ 7 & & & & & & 0,000 \end{bmatrix}$$

Métodos de Agrupamento Hierárquicos

Exemplo

Passo 2: juntar os casos 4 e 5

Redefinir a matriz de distâncias considerando os casos mais parecidos como se fossem um único grupo.

$$d_{((4,5)(1,2))} = \min(d_{14}; d_{24}; d_{15}; d_{25}) = \min(3,640; 3,500; 4,000; 4,123) = 3,500$$

$$= \min(d_{(1,2)4}; d_{(1,2)5}) = \min(3,500; 4,000)$$

$$d_{((4,5)3)} = \min(d_{34}; d_{35}) = \min(2,693; 3,606) = 2,693$$

$$d_{((4,5)6)} = \min(d_{46}; d_{56}) = \min(2,693; 2,828) = 2,693$$

$$d_{((4,5)7)} = \min(d_{47}; d_{57}) = \min(4,031; 5,000) = 4,031$$

Métodos de Agrupamento Hierárquicos

Exemplo

Matriz de distâncias

$$D_2 = \begin{bmatrix} & (1, 2) & 3 & (4, 5) & 6 & 7 \\ (1, 2) & 0,000 & 1,414 & 3,500 & 6,083 & 5,657 \\ 3 & & 0,000 & 2,693 & 5,000 & 4,243 \\ (4, 5) & & & 0,000 & 2,693 & 4,031 \\ 6 & & & & 0,000 & 3,606 \\ 7 & & & & & 0,000 \end{bmatrix}$$

Métodos de Agrupamento Hierárquicos

Exemplo

Matriz de distâncias

$$D_2 = \begin{bmatrix} & (1, 2) & 3 & (4, 5) & 6 & 7 \\ (1, 2) & 0,000 & \mathbf{1,414} & 3,500 & 6,083 & 5,657 \\ 3 & & 0,000 & 2,693 & 5,000 & 4,243 \\ (4, 5) & & & 0,000 & 2,693 & 4,031 \\ 6 & & & & 0,000 & 3,606 \\ 7 & & & & & 0,000 \end{bmatrix}$$