

# Análise Discriminante

## O Problema da classificação e discriminação

- ▶ Dois tipos de problemas recorrentes em análise de dados, e que podem ser abordados por técnicas multivariadas, são **discriminação** e **classificação**.

## O Problema da classificação e discriminação

- ▶ Dois tipos de problemas recorrentes em análise de dados, e que podem ser abordados por técnicas multivariadas, são **discriminação** e **classificação**.
- ▶ Em um problema de **discriminação**, o objetivo é aplicar e avaliar a contribuição de  $p$  variáveis na discriminação (separação) de  $k$  grupos **pré-definidos**;

## O Problema da classificação e discriminação

- ▶ Dois tipos de problemas recorrentes em análise de dados, e que podem ser abordados por técnicas multivariadas, são **discriminação** e **classificação**.
- ▶ Em um problema de **discriminação**, o objetivo é aplicar e avaliar a contribuição de  $p$  variáveis na discriminação (separação) de  $k$  grupos **pré-definidos**;
- ▶ Em um problema de **classificação**, o objetivo é construir uma regra, baseada em  $p$  variáveis e  $n$  indivíduos, que permita classificar novos indivíduos em um de  $k$  grupos **pré-definidos**.

## Discriminação em dois grupos

- Considere que desejamos discriminar indivíduos de duas populações  $\pi_1$  e  $\pi_2$  com base em  $p$  variáveis avaliadas  $x = [X_1, X_2, \dots, X_p]^t$ .

## Discriminação em dois grupos

- ▶ Considere que desejamos discriminar indivíduos de duas populações  $\pi_1$  e  $\pi_2$  com base em  $p$  variáveis avaliadas  $x = [X_1, X_2, \dots, X_p]^t$ .
- ▶ Considere ainda conhecidas  $\mu_1$ ,  $\mu_2$ ,  $\Sigma_1$  e  $\Sigma_2$ .

## Discriminação em dois grupos

- ▶ Considere que desejamos discriminar indivíduos de duas populações  $\pi_1$  e  $\pi_2$  com base em  $p$  variáveis avaliadas  $x = [X_1, X_2, \dots, X_p]^t$ .
- ▶ Considere ainda conhecidas  $\mu_1$ ,  $\mu_2$ ,  $\Sigma_1$  e  $\Sigma_2$ .
- ▶ Sejam  $f_1(x)$  e  $f_2(x)$  as funções (densidade) de probabilidade de  $x$  em  $\pi_1$  e  $\pi_2$ .

## Discriminação em dois grupos


- ▶ Considere que desejamos discriminar indivíduos de duas populações  $\pi_1$  e  $\pi_2$  com base em  $p$  variáveis avaliadas  $x = [X_1, X_2, \dots, X_p]^t$ .
- ▶ Considere ainda conhecidas  $\mu_1$ ,  $\mu_2$ ,  $\Sigma_1$  e  $\Sigma_2$ .
- ▶ Sejam  $f_1(x)$  e  $f_2(x)$  as funções (densidade) de probabilidade de  $x$  em  $\pi_1$  e  $\pi_2$ .
- ▶ Seja  $\Omega$  o espaço amostral (conjunto de resultados possíveis para  $x$ ).



## Classificação em dois grupos - Regras de classificação

- ▶ Vamos considerar uma partição de  $\Omega$  em dois conjuntos  $R_1$  e  $R_2$ ,  $(R_1 \cup R_2 = \Omega; R_1 \cap R_2 = \emptyset)$ , tal que:
  - ▶ Todo indivíduo tal que  $x \in R_1$  seja classificado como pertencente a  $\pi_1$ ;
  - ▶ Todo indivíduo tal que  $x \in \Omega - R_1 = R_2$  seja classificado como pertencente a  $\pi_2$ .

## Classificação em dois grupos - Ilustração



## Classificação em dois grupos - Probabilidades de má-classificação

Com base no que foi apresentado, temos as seguintes probabilidades:


- ▶  $P(2|1)$ : Probabilidade de classificar um indivíduo em  $\pi_2$  dado que ele pertence a  $\pi_1$ :

$$P(2|1) = P(x \in R_2 | \pi_1) = \int_{R_2} f_1(x) dx$$

- ▶  $P(1|2)$ : Probabilidade de classificar um indivíduo em  $\pi_1$  dado que ele pertence a  $\pi_2$ :

$$P(1|2) = P(x \in R_1 | \pi_2) = \int_{R_1} f_2(x) dx$$

## Classificação em dois grupos - Ilustração



## Classificação em dois grupos - Incorporando probabilidades a priori

Vamos assumir probabilidades a priori  $p_1 = P(\pi_1)$  e  $p_2 = P(\pi_2)$  de um indivíduo pertencer a  $\pi_1$  e  $\pi_2$ , respectivamente ( $p_1 + p_2 = 1$ ). Então:

- Probabilidade de um indivíduo ser classificado na população 1 ( $C_1$ ) e de fato pertencer a  $\pi_1$ :

$$P(C_1 \cap \pi_1) = P(C_1|\pi_1)P(\pi_1) = P(1|1)p_1$$

- Probabilidade de um indivíduo ser incorretamente classificado na população  $\pi_1$ :

$$P(C_1 \cap \pi_2) = P(C_1|\pi_2)P(\pi_2) = P(1|2)p_2$$

## Classificação em dois grupos - Incorporando probabilidades a priori

- Probabilidade de um indivíduo ser classificado na população 2 ( $C_2$ ) e de fato pertencer a  $\pi_2$ :

$$P(C_2 \cap \pi_2) = P(C_2|\pi_2)P(\pi_2) = P(2|2)p_2$$

- Probabilidade de um indivíduo ser incorretamente classificado na população  $\pi_2$ :

$$P(C_2 \cap \pi_1) = P(C_2|\pi_1)P(\pi_1) = P(2|1)p_1$$

## Classificação em dois grupos - Incorporando custos de má-classificação

Agora vamos incorporar custos de má-classificação:

- ▶ Seja  $c(1|2)$  o custo de classificar um indivíduo pertencente a  $\pi_2$  como pertencente a  $\pi_1$ ;

## Classificação em dois grupos - Incorporando custos de má-classificação

Agora vamos incorporar custos de má-classificação:

- ▶ Seja  $c(1|2)$  o custo de classificar um indivíduo pertencente a  $\pi_2$  como pertencente a  $\pi_1$ ;
- ▶ Seja  $c(2|1)$  o custo de classificar um indivíduo pertencente a  $\pi_1$  como pertencente a  $\pi_2$ ;



## Classificação em dois grupos - Incorporando custos de má-classificação

Agora vamos incorporar custos de má-classificação:

- ▶ Seja  $c(1|2)$  o custo de classificar um indivíduo pertencente a  $\pi_2$  como pertencente a  $\pi_1$ ;
- ▶ Seja  $c(2|1)$  o custo de classificar um indivíduo pertencente a  $\pi_1$  como pertencente a  $\pi_2$ ;

Naturalmente, consideramos  $c(1|1) = c(2|2) = 0$ .

## Classificação em dois grupos - Custo esperado de má-classificação ( $ECM$ )

Diferentes critérios podem ser utilizados para fins de determinar a regra de classificação. Um deles é a minimização do **custo esperado de má-classificação**.

- ▶ Para qualquer regra de classificação, o custo esperado de má-classificação ( $ECM$ ) fica dado por:

$$ECM = c(2|1)P(2|1)p_1 + c(1|2)P(1|2)p_2$$

- ▶ Assim, a melhor regra de classificação, baseada nesse critério, seria aquela que minimizasse  $ECM$ .

## Classificação em dois grupos - Regras de classificação para mínimo ( $ECM$ )

As regiões  $R_1$  e  $R_2$ , responsáveis por alocar qualquer observação  $x$  a  $\pi_1$  ou  $\pi_2$  (respectivamente), **tal que  $ECM$  seja mínimo**, são dadas por:

$$R_1 := \frac{f_1(x)}{f_2(x)} \geq \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right)$$

ou, de forma equivalente,  $p_1 c(2|1) f_1(x) \geq p_2 c(1|2) f_2(x)$ ;

$$R_2 := \frac{f_1(x)}{f_2(x)} < \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right)$$

ou, de forma equivalente,  $p_1 c(2|1) f_1(x) < p_2 c(1|2) f_2(x)$ .

## Classificação em dois grupos - casos particulares

- $p_1 = p_2$  (probabilidades a priori iguais):

$$R_1 := \frac{f_1(x)}{f_2(x)} \geq \left( \frac{c(1|2)}{c(2|1)} \right) \quad R_2 := \frac{f_1(x)}{f_2(x)} < \left( \frac{c(1|2)}{c(2|1)} \right)$$

- $c(1|2) = c(2|1)$  (custos de má-classificação iguais):

$$R_1 := \frac{f_1(x)}{f_2(x)} \geq \left( \frac{p_2}{p_1} \right) \quad R_2 := \frac{f_1(x)}{f_2(x)} < \left( \frac{p_2}{p_1} \right)$$

## Classificação em dois grupos - casos particulares

►  $p_1 = p_2$  e  $c(1|2) = c(2|1)$ :

$$R_1 := \frac{f_1(x)}{f_2(x)} \geq 1 \quad R_2 := \frac{f_1(x)}{f_2(x)} < 1$$

## Classificação em dois grupos - Classificação pelo Teorema de Bayes

Usando o teorema de Bayes, podemos alocar uma nova observação  $x_0$  à população com maior probabilidade a posteriori:

$$P(\pi_1|x_0) = \frac{p_1 f_1(x_0)}{p_1 f_1(x_0) + p_2 f_2(x_0)};$$

$$P(\pi_2|x_0) = 1 - P(\pi_1|x_0)$$

# Classificação em duas população normais

## 1º caso: as populações possuem variância comum

► Suponha agora que  $x$  segue a distribuição normal multivariada. Assim, temos que

$$f_i(x) = (2\pi)^{-p/2} |\Sigma|^{-1/2} \exp \left\{ -\frac{1}{2} (x - \mu_i)^t \Sigma^{-1} (x - \mu_i) \right\}$$

para  $i = 1, 2$  em que  $\mu_i$  é o vetor de médias da  $i$ -ésima população e  $\Sigma$  é a matriz de covariâncias positiva definida comum às duas populações.

# Classificação em duas população normais

## 1º caso: as populações possuem variância comum

- ▶ De acordo com a regra do mínimo custo esperado de má-classificação ( $ECM$ ), devemos classificar  $x$  em  $\pi_1$  se

$$\frac{f_1(x)}{f_2(x)} \geq \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right)$$

- ▶ Se substituirmos as densidades  $f_1(x)$  e  $f_2(x)$  pela densidade normal correspondente teremos:

$$\exp \left\{ -\frac{1}{2} (x - \mu_1)^t \Sigma^{-1} (x - \mu_1) + \frac{1}{2} (x - \mu_2)^t \Sigma^{-1} (x - \mu_2) \right\} \geq \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right)$$



# Classificação em duas população normais

## 1º caso: as populações possuem variância comum

► Que, depois de algum algebrismo, torna-se

$$\exp \left\{ (\mu_1 - \mu_2)^t \Sigma^{-1} x - \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2) \right\} \geq \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right)$$

► Como ambos os termos são positivos, podemos tomar o logaritmo preservando a ordem da desigualdade. Assim, devemos alocar  $x$  em  $\pi_1$  se

$$(\mu_1 - \mu_2)^t \Sigma^{-1} x - \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2) \geq \ln \left\{ \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right) \right\}$$

e em  $\pi_2$ , caso contrário.

## Classificação em duas população normais

### Para dados amostrais

Se considerarmos  $n_1$  observações  $p$ -variadas  $X_{11}, X_{12}, \dots, X_{1n_1}$  amostradas da população  $\pi_1$  e  $n_2$ ,  $X_{21}, X_{22}, \dots, X_{2n_2}$  amostradas da população  $\pi_2$ , com  $n_1 + n_2 - 2 \geq p$ , então a regra de alocação estimada que minimiza o custo médio de má-classificação é dada por: alocar  $x$  na população  $\pi_1$  se

$$(\bar{x}_1 - \bar{x}_2)^t S_c^{-1} x - \frac{1}{2} (\bar{x}_1 - \bar{x}_2)^t S_c^{-1} (\bar{x}_1 + \bar{x}_2) \geq \ln \left\{ \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right) \right\}$$

em que

$$S_c = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}$$

## Classificação em duas população normais

### 2º caso: as populações não possuem variância comum

Sob a suposição de homogeneidade das matrizes de covariâncias, verificamos que as regras de classificação originadas foram simples e lineares.

- Se considerarmos a situação geral em que  $f_1(x)$  e  $f_2(x)$  são modelos normais multivariados com parâmetros  $\mu_i$  e  $\Sigma_i$ ,  $i = 1, 2$ , sendo  $\Sigma_1 \neq \Sigma_2$ , devemos classificar  $x$  em  $\pi_1$ , se

$$-\frac{1}{2}x^t(\Sigma_1 - \Sigma_2)x + (\mu_1^t\Sigma_1^{-1} - \mu_2^t\Sigma_2^{-1})x - \delta \geq \ln \left\{ \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right) \right\}$$

e em  $\pi_2$ , caso contrário.

## Classificação em duas população normais

2º caso: as populações não possuem variância comum

► Sendo,

$$\delta = \frac{1}{2} \ln \left( \frac{|\Sigma_1|}{|\Sigma_2|} \right) + \frac{1}{2} (\mu_1^t \Sigma_1^{-1} \mu_1 - \mu_2^t \Sigma_2^{-1} \mu_2)$$

► Ao contrário do caso homocedástico, as regiões de classificação são definidas por funções discriminantes quadráticas de  $x$ .

# Classificação em duas população normais

## Para dados amostrais

- Podemos obter uma regra estimada substituindo os parâmetros  $\mu_i$  e  $\Sigma_i$ , pelos respectivos estimadores  $\bar{x}_i$  e  $S_i$ ,  $i = 1, 2$ . Assim, devemos alocar  $x$  na população  $\pi_1$  se

$$-\frac{1}{2}x^t(S_1 - S_2)x + (\bar{x}_1^t S_1^{-1} - \bar{x}_2^t S_2^{-1})x - \hat{\delta} \geq \ln \left\{ \left( \frac{c(1|2)}{c(2|1)} \right) \left( \frac{p_2}{p_1} \right) \right\}$$

e em  $\pi_2$ , caso contrário, sendo

$$\hat{\delta} = \frac{1}{2} \ln \left( \frac{|S_1|}{|S_2|} \right) + \frac{1}{2} (\bar{x}_1^t S_1^{-1} \bar{x}_1 - \bar{x}_2^t S_2^{-1} \bar{x}_2)$$

# Discriminação em duas populações

## A função discriminante linear de Fisher

- ▶ Suposição de linearidade: **Homocedasticidade!**

$$\Sigma_1 = \Sigma_2 = \Sigma$$

- ▶ Matriz de variância comum
- ▶ Não pressupõe normalidade multivariada dos dados!

# Discriminação em duas populações

## A função discriminante linear de Fisher

- ▶ Baseada na **distância de Mahalanobis** entre o indivíduo desconhecido  $x_0$  e as médias das populações:

$$d^2(x, \mu_i) = (x - \mu_i)^t \Sigma^{-1} (x - \mu_i), \quad i = 1, 2$$

- ▶ Intuitivamente, para um novo indivíduo  $x_0$ , se  $d^2(x_0, \mu_1) < d^2(x_0, \mu_2)$ , classificamos  $x_0$  em  $\pi_1$ . Caso contrário, classificamos  $x_0$  em  $\pi_2$

# Discriminação em duas populações

## A função discriminante linear de Fisher

- Expressando essa regra como uma função discriminante:

$$\begin{aligned}d^2(x, \mu_2) - d^2(x, \mu_1) &= (x - \mu_2)^t \Sigma^{-1} (x - \mu_2) - (x - \mu_1)^t \Sigma^{-1} (x - \mu_1) \\&= (\mu_2 - \mu_1)^t \Sigma^{-1} (\mu_2 + \mu_1) + 2x^t \Sigma^{-1} (\mu_1 - \mu_2)\end{aligned}$$

- A expressão acima pode ser reescrita como:

$$L(x) = \left[ x - \frac{1}{2}(\mu_1 + \mu_2) \right]^t \Sigma^{-1} (\mu_1 - \mu_2)$$



# Discriminação em duas populações

## A função discriminante linear de Fisher

► Ou ainda...

$$L(x) = (\mu_1 - \mu_2)^t \Sigma^{-1} x - \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2)$$

► O primeiro termo

$$D(x) = (\mu_1 - \mu_2)^t \Sigma^{-1} x$$

é chamado de **função discriminante linear de Fisher**.

# Discriminação em duas populações

## A função discriminante linear de Fisher

► Observe o segundo termo de

$$L(x) = (\mu_1 - \mu_2)^t \Sigma^{-1} x - \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2)$$

após algum algebrismo,

$$\begin{aligned} m &= \frac{1}{2} (\mu_1 - \mu_2)^t \Sigma^{-1} (\mu_1 + \mu_2) \\ &= \frac{1}{2} [(\mu_1 - \mu_2)^t \Sigma^{-1} \mu_1 + (\mu_1 - \mu_2)^t \Sigma^{-1} \mu_2] \\ &= \frac{1}{2} [D(\mu_1) + D(\mu_2)] \end{aligned}$$

# Discriminação em duas populações

## A função discriminante linear de Fisher

- ▶ A regra de classificação fica: Se  $D(x_0) > m$ , classificamos  $x_0$  em  $\pi_1$ . Caso contrário, classificamos  $x_0$  em  $\pi_2$ .
- ▶ É interessante observar que  $(\mu_1 - \mu_2)^t \Sigma^{-1} x = b^t x$ , onde  $b^t = (\mu_1 - \mu_2)^t \Sigma^{-1}$  é um vetor de dimensão  $1 \times p$ .
- ▶ Desse modo, a **função discriminante de Fisher** tem a forma:

$$(\mu_1 - \mu_2)^t \Sigma^{-1} x = b^t x = b_1 x_1 + b_2 x_2 + \cdots + b_p x_p$$

# Discriminação em duas populações

Para dados amostrais

$$\widehat{D}(x) = (\bar{x}_1 - \bar{x}_2)^t S_c^{-1} x$$

$$\widehat{m} = \frac{1}{2} [\widehat{D}(\bar{x}_1) + \widehat{D}(\bar{x}_2)]$$

$$S_c = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}$$

# Probabilidade de classificação incorreta

## Estimação das probabilidades de classificação incorreta

► Seja a seguinte tabela:

Frequências dos erros de classificação

| População de origem | Classe 1 | Classe 2 | Total |
|---------------------|----------|----------|-------|
| 1                   | $n_{11}$ | $n_{12}$ | $n_1$ |
| 2                   | $n_{21}$ | $n_{22}$ | $n_2$ |

$n_{ij}$  : é o número de elementos de  $i$  classificados em  $j$

# Probabilidade de classificação incorreta

## Estimação das probabilidades de classificação incorreta

- ▶ Com base nessas quantidades, podemos estimar as probabilidades de ocorrência dos erros 1 e 2 por:

$$\hat{p}(2|1) = \frac{n_{12}}{n_1} \quad \text{e} \quad \hat{p}(1|2) = \frac{n_{21}}{n_2}$$

- ▶ Além disso, podemos estimar a probabilidade global de acerto da função discriminante por:

$$\hat{p}(acerto) = \frac{n_{11} + n_{22}}{n_1 + n_2}$$

# Probabilidade de classificação incorreta

## Estimação das probabilidades de classificação incorreta

- Podemos também, estimar a taxa de erro aparente (TEA):

$$TEA = \frac{n_{12} + n_{21}}{n_1 + n_2}$$

## Probabilidade de classificação incorreta

- ▶ Três métodos de determinação dessas probabilidades:
  - ▶ **Método da ressubstituição:** os mesmos dados são utilizados para estimar e validar a função discriminante.
  - ▶ **Método da ressubstituição com divisão amostral:** os dados são divididos em duas subamostras - treinamento: estima a fd, validação: estima as probabilidades de erro.
  - ▶ **Método da validação cruzada:** a cada iteração é omitida uma observação e a fd é estimada a partir das demais. A observação omitida é utilizada para estimar as probabilidades de erro.



## Classificação em $k$ grupos

- ▶ Sejam  $f_1(x), f_2(x), \dots, f_k(x)$  as distribuições do vetor aleatório  $x$  em cada uma de  $k$  populações,  $\pi_1, \pi_2, \dots, \pi_k$ ;

## Classificação em $k$ grupos

- ▶ Sejam  $f_1(x), f_2(x), \dots, f_k(x)$  as distribuições do vetor aleatório  $x$  em cada uma de  $k$  populações,  $\pi_1, \pi_2, \dots, \pi_k$ ;
- ▶ Sejam  $p_1, p_2, \dots, p_k$  as probabilidades a priori e  $c(i|j)$ ,  $i, j = 1, 2, \dots, k$ , os custos de má-classificação.

## Classificação em $k$ grupos

- ▶ Sejam  $f_1(x), f_2(x), \dots, f_k(x)$  as distribuições do vetor aleatório  $x$  em cada uma de  $k$  populações,  $\pi_1, \pi_2, \dots, \pi_k$ ;
- ▶ Sejam  $p_1, p_2, \dots, p_k$  as probabilidades a priori e  $c(i|j)$ ,  $i, j = 1, 2, \dots, k$ , os custos de má-classificação.
- ▶ Seja  $R_i$  o conjunto dos  $x$ 's classificados como  $\pi_i$ ,  $i = 1, 2, \dots, k$ , e

$$P(j|i) = \int_{R_j} f_i(x) dx \quad i, j = 1, 2, \dots, k$$

## Classificação em $k$ grupos

- Custo esperado de má classificação:

$$ECM = p_1 ECM(1) + p_2 ECM(2) + \dots + p_k ECM(k)$$

em que,

$$ECM(i) = P(1|i)c(1|i) + P(2|i)c(2|i) + \dots + P(k|i)c(k|i), \quad i = 1, 2, \dots, k$$

## Classificação em $k$ grupos

- Custo esperado de má classificação:

$$ECM = p_1 ECM(1) + p_2 ECM(2) + \dots + p_k ECM(k)$$

em que,

$$ECM(i) = P(1|i)c(1|i) + P(2|i)c(2|i) + \dots + P(k|i)c(k|i), \quad i = 1, 2, \dots, k$$

- A regra de classificação **tal que  $ECM$  seja mínimo** consiste em classificar uma observação  $x$  no grupo  $j$  tal que:

$$\sum_{i=1, i \neq j}^k p_i f_i(x) c(j|i), \quad \text{seja mínimo.}$$

## Classificação em $k$ grupos

- ▶ Assim, deve-se classificar  $x$  em  $\pi_j$  caso a média dos custos de classificações incorretas nas demais populações seja mínima.

## Classificação em $k$ grupos

- ▶ Assim, deve-se classificar  $x$  em  $\pi_j$  caso a média dos custos de classificações incorretas nas demais populações seja mínima.
- ▶ Observe que para  $k = 2$  populações, essa regra de classificação fica simplificada, sendo dada pela regra de classificação para duas populações apresentada anteriormente.

## Classificação em mais de duas população normais

- Suponha agora que  $x$  segue a distribuição normal multivariada. Assim, temos que

$$f_i(x) = (2\pi)^{-p/2} |\Sigma_i|^{-1/2} \exp \left\{ -\frac{1}{2} (x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) \right\}$$

para  $i = 1, 2, \dots, k$  em que  $\mu_i$  é o vetor de médias da  $i$ -ésima população e  $\Sigma_i$  é a matriz de covariâncias positiva definida da  $i$ -ésima população.



## Classificação em mais de duas população normais

- Considerando que estes parâmetros são conhecidos, então pela regra de classificação de mínima probabilidade total de classificação incorreta, devemos classificar  $x$  na população  $\pi_i$  se

$$\begin{aligned}\ln [p_i f_i(x)] &= \ln (p_i) - \frac{p}{2} \ln (2\pi) - \frac{1}{2} \ln (|\Sigma_i|) - \frac{1}{2} (x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) \\ &= \max_j \ln [p_j f_j(x)]\end{aligned}$$

- Alocamos a observação  $x$  à população que maximiza  $\ln [p_j f_j(x)]$ , em relação a todos os valores de  $j$ ,  $j = 1, 2, \dots, k$ .

## Classificação em mais de duas população normais

- ▶ O termo  $\frac{p}{2} \ln(2\pi)$  é constante para todas as  $k$  populações e pode ser ignorado.

## Classificação em mais de duas população normais

- ▶ O termo  $\frac{p}{2} \ln(2\pi)$  é constante para todas as  $k$  populações e pode ser ignorado.
- ▶ O termo resultante é denominado de escore quadrático de discriminação e para a  $i$ -ésima população é dado por

$$d_i^Q(x) = -\frac{1}{2} \ln(|\Sigma_i|) - \frac{1}{2} (x - \mu_i)^t \Sigma_i^{-1} (x - \mu_i) + \ln(p_i)$$

## Classificação em mais de duas população normais

- Utilizando o escore quadrático  $d_i^Q(x)$  de discriminação, podemos simplificar a regra de classificação. Classificamos  $x$  em  $\pi_i$  se

$$d_i^Q(x) = \max_j \left[ d_j^Q(x) \right]$$

para  $j = 1, 2, \dots, k$ .

# Classificação em mais de duas população normais

## Para dados amostrais

- ▶ Podemos obter uma regra estimada substituindo os parâmetros  $\mu_i$  e  $\Sigma_i$ , pelos respectivos estimadores  $\bar{x}_i$  e  $S_i$ ,  $i = 1, 2, \dots, k$ .
- ▶ O estimador da função quadrática  $d_i^Q(x)$  é representado por  $Q_i(x)$  e é dado por

$$Q_i(x) = -\frac{1}{2} \ln(|S_i|) - \frac{1}{2} (x - \bar{x}_i)^t S_i^{-1} (x - \bar{x}_i) + \ln(p_i)$$

para  $i = 1, 2, \dots, k$  e, pela regra estimada de mínima probabilidade total de classificação incorreta, devemos classificar a observação  $x$  em  $\pi_i$  se

$$Q_i(x) = \max_j [Q_j(x)] , \quad j = 1, 2, \dots, k$$

## Classificação em mais de duas população normais

► No caso particular em que  $\Sigma_1 = \Sigma_2 = \dots = \Sigma_k = \Sigma$ :

$$d_i^Q(x) = -\frac{1}{2} \ln(|\Sigma|) - \frac{1}{2} (x - \mu_i)^t \Sigma^{-1} (x - \mu_i) + \ln(p_i)$$

para  $i = 1, 2, \dots, k$ .

## Classificação em mais de duas população normais

- ▶ No caso particular em que  $\Sigma_1 = \Sigma_2 = \dots = \Sigma_k = \Sigma$ :

$$d_i^Q(x) = -\frac{1}{2} \ln(|\Sigma|) - \frac{1}{2} (x - \mu_i)^t \Sigma^{-1} (x - \mu_i) + \ln(p_i)$$

para  $i = 1, 2, \dots, k$ .

- ▶ Se ignorarmos os termos constantes a todas as  $k$  populações, obtemos o escore discriminante linear  $d_i(x)$

$$d_i(x) = \mu_i^t \Sigma^{-1} x - \frac{1}{2} \mu_i^t \Sigma^{-1} \mu_i + \ln(p_i)$$

para  $i = 1, 2, \dots, k$ .

## Classificação em mais de duas população normais

- Portanto, devemos classificar  $x$  em  $\pi_i$  se

$$d_i(x) = \max_j [d_j(x)] , \quad j = 1, 2, \dots, k$$



# Classificação em mais de duas população normais

## Para dados amostrais

- Uma estimativa dessa regra de classificação é obtida substituindo os parâmetros pelas estimativas.

$$\hat{d}_i(x) = \bar{x}_i^t S_c^{-1} x - \frac{1}{2} \bar{x}_i^t S_c^{-1} \bar{x}_i + \ln(p_i)$$

sendo

$$S_c = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2 + \cdots + (n_k - 1)S_k}{n_1 + n_2 + \cdots + n_k - k}$$

para  $i = 1, 2, \dots, k$ .

# Classificação em mais de duas população normais

Para dados amostrais

► Devemos classificar  $x$  em  $\pi_i$ , se

$$\hat{d}_i(x) = \max_j \left[ \hat{d}_j(x) \right], \quad j = 1, 2, \dots, k$$

# Classificação em mais de duas população normais

## Funções discriminantes de Fisher para mais de duas populações

- Suposição de linearidade: **Homocedasticidade!**

$$\Sigma_1 = \Sigma_2 = \dots = \Sigma_k = \Sigma$$

- A ideia é construir  $s$  combinações lineares, chamadas de **funções discriminantes canônicas**, dadas por:

$$\widehat{Y}_j = \widehat{e}_j^t x, \quad j = 1, \dots, s \leq \min(k-1, p)$$

em que  $\widehat{e}_j$  é o  $j$ -ésimo autovetor corresponde ao  $j$ -ésimo maior autovalor da matriz  $W^{-1}B$  e tal que  $\widehat{e}_j^t W \widehat{e}_j = 1$

# Classificação em mais de duas população normais

## Funções discriminantes de Fisher para mais de duas populações

- Sendo a **matriz de soma de quadrados e produtos cruzados intra grupos**  $W_{p \times p}$  e a **matriz de soma de quadrados e produtos cruzados entre grupos**  $B_{p \times p}$ , definidas respectivamente, por:

$$W = \sum_{i=1}^k \sum_{b=1}^{n_i} (x_{ib} - \bar{x}_i)(x_{ib} - \bar{x}_i)^t$$

$$B = \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})(\bar{x}_i - \bar{x})^t$$

# Classificação em mais de duas população normais

Funções discriminantes de Fisher para mais de duas populações

Regra de classificação

- ▶ Para cada indivíduo teremos um vetor com os seus escores nas funções, denotado por  $\widehat{Y}_j$
- ▶ Teremos também, os escores das funções discriminantes aplicadas aos vetores de médias amostrais observados para cada população, denotado por  $\widehat{Y}_i$

# Classificação em mais de duas população normais

Funções discriminantes de Fisher para mais de duas populações

Regra de classificação

- Calcula-se a distância Euclidiana entre os vetores  $\widehat{Y}_j$  e  $\widehat{Y}_i$ , para todo  $i = 1, \dots, k$

$$d = (\widehat{Y}_j - \widehat{Y}_i)^t (\widehat{Y}_j - \widehat{Y}_i)^{\frac{1}{2}}$$

- **Classifica-se o indivíduo na população cuja distância é a menor**

## Probabilidade de classificação incorreta

Os erros de classificação são definidos como:

- ▶ **Erro(i,j):** o elemento amostral pertence à população  $\pi_j$  mas a regra de classificação o aloca na população  $\pi_i$ ,  $i, j = 1, \dots, g$ ,  $i \neq j$ .

## Probabilidade de classificação incorreta

Os erros de classificação são definidos como:

- **Erro(i,j):** o elemento amostral pertence à população  $\pi_j$  mas a regra de classificação o aloca na população  $\pi_i$ ,  $i, j = 1, \dots, g$ ,  $i \neq j$ .

E as probabilidades de ocorrência destes erros são estimadas por:

$$\hat{p}(i|j) = \frac{n_{ji}}{n_j}$$

onde  $n_{ji}$  é o número de elementos da população  $\pi_j$  classificados incorretamente pela regra na população  $\pi_i$ ,  $i, j = 1, \dots, g$ ,  $i \neq j$ .